

Sistema Inteligente de Previsão de Consumo Alimentar para Animais de Rua baseado em Machine Learning

Giovanna da Costa Silva¹, Luíza Liao¹, Luiza Sayuri Kawakami¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{giovannacosta.silva, luiza.liao, luiza.kawakami}@mackenzista.com.br

Resumo. *Este trabalho propõe o desenvolvimento de um sistema inteligente para monitoramento e previsão do consumo alimentar de animais em situação de rua, denominado HoneyDrop. A proposta surge da dificuldade em controlar a reposição de alimento, o que pode gerar desperdício ou escassez. O sistema considera um comedouro inteligente como fonte de dados, permitindo o monitoramento do consumo alimentar. A partir desses dados, são aplicadas técnicas de Inteligência Artificial para analisar o comportamento de consumo e prever a necessidade de reabastecimento.*

A metodologia baseia-se na utilização de dados simulados, representando o consumo ao longo do tempo, com posterior análise exploratória e aplicação de modelos de regressão por meio de ferramentas de Machine Learning. Espera-se identificar padrões de consumo e gerar previsões que auxiliem na tomada de decisão de voluntários.

O projeto contribui para a melhoria da gestão alimentar de animais em situação de vulnerabilidade, aliando tecnologia e impacto social.

Palavras-chave: *Inteligência Artificial; Machine Learning; Previsão; Animais de rua.*

Abstract. *This work proposes the development of an intelligent system for monitoring and predicting food consumption of animals in street situations, called HoneyDrop. The proposal arises from the difficulty in controlling food replenishment, which can lead to waste or shortage. The system considers a smart feeder as a data source, enabling the monitoring of food consumption. Based on these data, Artificial Intelligence techniques are applied to analyze consumption behavior and predict the need for replenishment.*

The methodology is based on the use of simulated data representing consumption over time, followed by exploratory data analysis and the application of regression models using Machine Learning tools. It is expected to identify consumption patterns and generate predictions that support volunteers in decision-making.

The project contributes to improving food management for animals in vulnerable conditions, combining technology and social impact.

Keywords: *Artificial Intelligence; Machine Learning; Street animals.*

1. Introdução

O cuidado com animais em situação de rua representa um desafio recorrente em centros urbanos, especialmente no que se refere à garantia de alimentação adequada. Em muitos casos, a reposição de ração em comedouros depende exclusivamente da ação de voluntários, o que pode resultar em falhas no abastecimento ou desperdício de recursos, devido à ausência de monitoramento contínuo e de dados confiáveis sobre o consumo alimentar. Nesse contexto, o uso de tecnologias como a Internet das Coisas (IoT) possibilita o monitoramento do consumo por meio de dispositivos inteligentes, enquanto a Inteligência Artificial (IA) surge como uma alternativa promissora para análise desses dados e apoio à tomada de decisão.

Apesar da existência de soluções tecnológicas voltadas ao monitoramento, o controle da alimentação de animais em situação de rua ainda é, em grande parte, realizado de forma manual e sem o apoio de dados estruturados. Essa abordagem pode gerar ineficiências, como a falta de alimento em determinados períodos ou o desperdício decorrente de reposições desnecessárias. Além disso, a ausência de análise de dados impede a identificação de padrões de consumo, dificultando a adoção de estratégias mais eficientes. Diante disso, surge a necessidade de soluções que não apenas monitorem, mas também analisem e prevejam o comportamento de consumo alimentar.

Neste contexto, este trabalho propõe o desenvolvimento de um sistema inteligente, denominado HoneyDrop, que utiliza dados provenientes de um comedouro inteligente como base para aplicação de técnicas de Machine Learning. A proposta busca identificar padrões de consumo ao longo do tempo e prever o momento ideal para reabastecimento, contribuindo para uma gestão mais eficiente e orientada por dados.

O objetivo geral deste trabalho é desenvolver um modelo preditivo capaz de estimar o consumo de ração com base em dados coletados ao longo do tempo. Como objetivos específicos, destacam-se: a criação de um conjunto de dados representativo do consumo alimentar; a realização de análise exploratória para identificação de padrões; e a aplicação de técnicas de regressão para previsão do consumo.

A relevância deste estudo está na aplicação prática da Inteligência Artificial em um problema real de impacto social, promovendo melhores condições de alimentação para animais em situação de vulnerabilidade. Além disso, o projeto contribui para a área de ciência de dados ao demonstrar o uso de técnicas preditivas em cenários do cotidiano.

Este projeto enquadra-se na opção de uso de frameworks de Machine Learning, utilizando ferramentas como a biblioteca scikit-learn para a construção de modelos preditivos baseados em dados de consumo alimentar.

Este documento está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico; a Seção 3 descreve a metodologia adotada; a Seção 4 apresenta os aspectos éticos relacionados ao uso da Inteligência Artificial; a Seção 5 discute os resultados esperados; e, por fim, a Seção 6 apresenta as conclusões do trabalho.

2. Referencial Teórico

A Inteligência Artificial (IA) tem se consolidado como uma das principais áreas da computação, sendo amplamente utilizada para resolver problemas complexos por meio da análise de dados e da automação de decisões. Segundo Russell e Norvig (2021), a IA pode ser definida como o estudo de agentes capazes de perceber o ambiente e tomar decisões que maximizem seus objetivos. Dentro desse contexto, o Machine Learning destaca-se por permitir que sistemas aprendam padrões a partir de dados históricos, possibilitando a construção de modelos preditivos.

O Machine Learning engloba diferentes técnicas voltadas à previsão e análise de dados, sendo a regressão uma das abordagens mais utilizadas quando se deseja estimar valores contínuos. De acordo com Coppin (2010), modelos de regressão são aplicados em cenários nos quais é necessário prever comportamentos futuros com base em tendências observadas. No contexto deste trabalho, essa técnica é utilizada para prever o consumo de ração ao longo do tempo, auxiliando na estimativa do momento ideal para reabastecimento.

Além das técnicas de IA, é importante considerar a origem dos dados utilizados nos modelos. Nesse sentido, a Internet das Coisas (IoT) desempenha um papel relevante ao possibilitar a coleta automatizada de informações por meio de dispositivos inteligentes, como sensores e atuadores. Conforme descrito por Evans (2011), a IoT permite a integração entre dispositivos físicos e sistemas computacionais, possibilitando o monitoramento contínuo de variáveis do ambiente. No contexto do HoneyDrop, o comedouro inteligente atua como fonte de dados, fornecendo informações sobre o consumo alimentar.

Outro aspecto fundamental em projetos de ciência de dados é a análise exploratória de dados, etapa responsável por compreender a estrutura das informações, identificar padrões e orientar a escolha dos modelos mais adequados. O uso de ferramentas como Pandas e Matplotlib possibilita a manipulação e visualização dos dados, contribuindo para uma melhor interpretação dos resultados e para a construção de modelos mais eficientes.

Por fim, destaca-se a crescente aplicação de técnicas de Inteligência Artificial em problemas de impacto social. A utilização de modelos preditivos permite otimizar recursos e melhorar processos em diferentes áreas, incluindo iniciativas voltadas ao bem-estar animal. Nesse contexto, a integração entre dados coletados por dispositivos IoT e técnicas de Machine Learning possibilita a criação de soluções mais inteligentes e eficientes, capazes de apoiar a tomada de decisão e gerar benefícios sociais relevantes.

3. Metodologia

A metodologia do projeto foi dividida em cinco etapas principais: criação do dataset, análise exploratória, preparação dos dados, treinamento do modelo e avaliação dos resultados.

Na primeira etapa, foi criado um dataset simulado em Python, representando o consumo de ração em um comedouro inteligente durante 30 dias. Foram consideradas quatro medições diárias, contendo informações como data, hora, temperatura, período do dia, peso inicial da ração, consumo, peso final e necessidade de reabastecimento.

Na segunda etapa, foi realizada a análise exploratória dos dados. Foram verificadas as primeiras linhas do dataset, sua estrutura, os tipos de variáveis, as estatísticas descritivas e a presença de valores ausentes. Também foram gerados gráficos para analisar o consumo médio por período do dia, o consumo médio por horário e a relação entre temperatura e consumo.

Na terceira etapa, foi feita a preparação dos dados para o modelo. As variáveis categóricas foram transformadas em variáveis numéricas por meio da técnica de one-hot encoding. Em seguida, foram definidas as variáveis de entrada e a variável-alvo. A variável-alvo escolhida foi consumo_g, pois o objetivo do projeto é prever a quantidade de ração consumida.

Para evitar vazamento de dados, foram removidas das variáveis de entrada as colunas peso_final_g e reabastecimento, pois ambas dependem do consumo já ocorrido. Assim, o modelo foi treinado apenas com informações que estariam disponíveis antes da previsão.

Na quarta etapa, foi aplicado um modelo de Regressão Linear utilizando a biblioteca scikit-learn. Os dados foram divididos em conjunto de treino e teste, permitindo avaliar o desempenho do modelo em dados não utilizados no treinamento.

Por fim, na quinta etapa, o modelo foi avaliado por meio das métricas MAE, RMSE e R^2 . Também foi gerado um gráfico comparando os valores reais e os valores previstos de consumo, permitindo analisar visualmente o desempenho da previsão.

4. Aspectos Éticos do Uso de Inteligência Artificial

A aplicação de técnicas de Inteligência Artificial neste projeto baseia-se na utilização de dados simulados que representam o consumo alimentar de animais em situação de rua. Dessa forma, não há coleta de dados pessoais ou sensíveis de indivíduos, o que elimina riscos relacionados à privacidade e à proteção de dados, atendendo aos princípios éticos de uso responsável da informação.

Apesar disso, é fundamental considerar aspectos relacionados à confiabilidade e à interpretação dos resultados gerados pelos modelos de Machine Learning. Como os dados utilizados são simulados, existe a possibilidade de divergência em relação ao comportamento real, o que exige cautela na análise das previsões e na sua aplicação em cenários práticos. Dessa forma, o sistema deve ser compreendido como uma ferramenta de apoio à tomada de decisão, não substituindo a atuação humana.

Além disso, o projeto apresenta um potencial impacto social positivo, ao propor uma solução que busca melhorar a gestão da alimentação de animais em situação de vulnerabilidade. A utilização da Inteligência Artificial, nesse contexto, visa otimizar recursos e apoiar voluntários, contribuindo para práticas mais eficientes e sustentáveis.

Por fim, o desenvolvimento do projeto considera princípios éticos como transparência, responsabilidade e uso consciente da tecnologia, garantindo que a aplicação da Inteligência Artificial esteja alinhada com benefícios sociais e com boas práticas no desenvolvimento de soluções tecnológicas.

5. Resultados Obtidos

Após a criação do dataset simulado, foi realizada a análise exploratória dos dados com o objetivo de compreender melhor o comportamento do consumo de ração antes da aplicação do modelo de Machine Learning. O conjunto de dados possui 120 registros, correspondentes a 30 dias de funcionamento simulado do comedouro inteligente, com quatro medições diárias.

Inicialmente, foram analisadas as primeiras linhas do dataset, sua estrutura, os tipos de dados e a presença de valores ausentes. A verificação mostrou que o dataset não possui dados nulos, não sendo necessário realizar tratamento de valores ausentes. Também foram calculadas estatísticas descritivas das variáveis numéricas, como hora, temperatura, peso inicial, consumo, peso final e reabastecimento.

A análise exploratória indicou que o consumo médio de ração foi de aproximadamente 130,87 g, com valor mínimo de 54 g e valor máximo de 214 g. A temperatura variou entre 22°C e 33°C, enquanto o peso inicial da ração apresentou média de aproximadamente 612,69 g. Também foram gerados gráficos para analisar o consumo médio por período do dia, o consumo médio por horário e a relação entre temperatura e consumo.

Após essa etapa, foi realizada a preparação dos dados para o modelo. As variáveis categóricas, como período e dia da semana, foram transformadas em variáveis numéricas por meio da técnica de one-hot encoding. Em seguida, os dados foram separados em variáveis de entrada e variável-alvo.

A variável-alvo definida foi o consumo de ração em gramas (`consumo_g`). Para evitar vazamento de dados, foram removidas das variáveis de entrada as colunas `peso_final_g` e `reabastecimento`, pois essas informações dependem do consumo já ocorrido. Dessa forma, o modelo foi treinado apenas com variáveis disponíveis antes da previsão, como hora, temperatura, dia da semana, período e peso inicial da ração.

Foi aplicado um modelo de Regressão Linear utilizando a biblioteca `scikit-learn`. O modelo apresentou MAE de 12,99 g, RMSE de 16,79 g e R^2 de 0,829. Esses resultados indicam que o modelo obteve bom desempenho na previsão do consumo de ração, com erro médio relativamente baixo e capacidade de explicar aproximadamente 82,9% da variação dos dados.

O gráfico de comparação entre os valores reais e previstos demonstrou que o modelo conseguiu acompanhar a tendência geral do consumo. Apesar de algumas diferenças entre os valores reais e estimados, os resultados mostram que a aplicação de Machine Learning é viável para apoiar a previsão do consumo alimentar no contexto do HoneyDrop.

6. Conclusão

Este trabalho apresentou a proposta de desenvolvimento de um sistema inteligente para monitoramento e previsão do consumo alimentar de animais em situação de rua, utilizando técnicas de Inteligência Artificial aplicadas a dados provenientes de um comedouro inteligente. O problema abordado está relacionado à dificuldade de controle no reabastecimento de ração, o que pode resultar em desperdício ou escassez de alimento.

A partir da definição dos objetivos e da metodologia proposta, observou-se que a utilização de modelos de Machine Learning possui potencial para identificar padrões de consumo e apoiar a previsão da necessidade de reposição de ração. Dessa forma, o projeto demonstra a viabilidade da aplicação da Inteligência Artificial como ferramenta de apoio à tomada de decisão em um contexto de impacto social.

Como limitação desta etapa do trabalho, destaca-se a utilização de dados simulados, que podem não representar integralmente o comportamento real dos animais. No entanto, essa abordagem é adequada para a validação inicial da proposta e para a construção do modelo preditivo.

Como trabalhos futuros, pretende-se utilizar dados reais coletados por dispositivos baseados em Internet das Coisas (IoT), além de integrar o sistema a plataformas de monitoramento em tempo real, ampliando sua aplicabilidade e potencial de impacto.

7. Referências bibliográficas

As citações e as referências bibliográficas devem seguir as normas definidas pela ABNT - NBR 6023 (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2018). Apenas os trabalhos citados devem ser indicados.

Para citações em linha, em que o autor é citado de forma corrida, deve ser utilizado o estilo considerando o sobrenome dos autores com apenas a primeira letra maiúscula, seguido da data de publicação da obra entre parênteses. Exemplos: Segundo Coppin (2010)[...]; De acordo com Arora et al. (2021)[...]; Na visão de Russel e Norvig (2021)[...].

Para citações em final de parágrafo, a citação deve ser realizada entre parênteses, considerando o sobrenome do autor completamente em maiúsculo, seguido pela data de publicação. Os autores e as obras devem ser separados por ponto e vírgula(;), já a data deve ser separada por vírgula (,). Exemplos: (SZELISKI, 2021), (RUSSELL; NORVIG, 2021; SZELISKI, 2021), (HAMEED et al., 2019; ARORA et al., 2021; KARTHIK et al., 2022).

Referências bibliográficas

ALAPARTHI, A.; MUNDURU, V.; MADDULURI, S. et al. Enhancing Pet Care with IoT: The Development of a Smart Pet Feeder. Coimbatore: IEEE, 2024.

CONSELHO REGIONAL DE MEDICINA VETERINÁRIA DA PARAÍBA (CRMV-PB). João Pessoa, 2023. Disponível em: <https://www.crmvpb.org.br/30-milhoes-de-animais-vivem-nas-rua-crmv-pb-defende-politica-de-controle-populacional/>.

COPPIN, B. Artificial Intelligence Illuminated. Sudbury: Jones and Bartlett Publishers, 2010.

EVANS, D. The Internet of Things: How the Next Evolution of the Internet Is Changing Everything. San Jose, CA: Cisco, 2011.

LAUDON, K.; LAUDON, J. Sistemas de Informação Gerenciais. 13. ed. São Paulo: Pearson, 2019.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável. [S. l.]: [s. n.], 2015. Disponível em: <https://brasil.un.org/sites/default/files/2020-09/agenda2030-pt-br.pdf>

PRESSMAN, R. Engenharia de Software. 8. ed. Porto Alegre: McGraw-Hill Education, 2016.

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. Upper Saddle River: Pearson, 2021.

SAADOON, A.; KOYUNCU, H. Intelligence Feeder System for Stray Cats. [S. l.]: Indonesian Journal of Electrical Engineering and Computer Science, 2023.

NILSSON, Nils J. Artificial Intelligence: A New Synthesis. San Francisco: Morgan Kaufmann Publishers, 1998.

Link GitHub: <https://github.com/giovannacostasi/honeydrop-ia>